

RAG 项目

修复低质量工业 PDF 的解析与 信息丢失工单

八维文化与产业研究院

2026 年 1 月



1 基本信息

工单对应的项目名称	RAG
工单编号	人工智能 NLP-RAG-修复低质量工业 PDF 的解析与信息丢失工单
创建时间	2026 年 1 月 23 日
创建人	王洪荣

2 任务描述

任务描述	目标: 针对 IMDR 数据集中低分辨率、格式复杂的图片型 PDF, 修复 RAGFlow 解析流水线中导致图文信息丢失、关联错误的缺陷, 锻炼多模态数据处理与代码调试能力。 任务需求: 公司想要快速搭建一套 RAG 系统, 用于实现中文工业技术文档多模态推理问答的功能, 中文工业技术文档多模态推理问答的数据集如附件所示: /original_problems/documents 目录里有 1700 个文件; IMDR: 一个专为工业制造领域的多模态理解与推理任务设计的数据集。该数据集涵盖了大量源自工业技术文档和装备制造相关专利的中文问题, 具有高度专业性与真实性。ITMQ 共包
------	---

含 10,096 个精心挑选的多模态问题 (questions.jsonl)，问题类型主要分为三类，

Only-Text-Question	Only-Image-Question	Text-Image-Question
Question: 根据文本信息，本发明方法中所述的反应器优选为什么类型的反应器？ Options: A. 固定床反应器 B. 釜式反应器 C. 可倾斜的盘式反应器 D. 塔式反应器 Document: CN100398667C.pdf Answer: C	Question: 在文件中第15页的图中，标号24的部件相对于标号22的部件的位置关系是什么？ Options: A. 位于标号22部件的上方 B. 位于标号22部件的右端并与之相连 C. 位于标号22部件的下方 D. 位于标号22部件的左端  Document: CN100531869C.pdf Answer: B	Question: 在文件中第12页的示意图中，如果柱塞(11)向下运动，会发生什么情况？ Options: A. 气体阀(9)关闭 B. 气体阀(9)打开，允许气体通过开口(33)进入箔衬袋(2) C. 液体供应管线(5)被打开 D. 填充阀(6)关闭，阻止液体进入  Document: CN100581923C.pdf Answer: A

如图 1 所示：纯文本问题、纯图像问题，以及文本-图像混合问题，全面覆盖了工业生产过程中常见的多种复杂情况。

此外，ITMQ 还具有两个领域数据特征：

首先，ITMQ 并不直接提供可编辑的文本信息或标准图像数据，而是以不可编辑的图片型 PDF 文档形式呈现。这些文档通常分辨率较低、格式不一、内容复杂，对模型的感知与解析能力提出了更高要求。

其次，数据集中包含大量交错的文本-图像类型问题。模型在回答此类问题时，需同时理解文本描述和技术图纸，并通过模块功能分析或机械原理推理完成问题解答，这对模型的多模态融合与推理能力构成严峻考验。

questions.jsonl 里是要测试的问题列表；

任务一：部署运行成功 RAGFlow 项目，git 地址：

<https://github.com/infiniflow/ragflow>


RAGFlow 的系统架构有两个核心组件：API 服务器（API Server）和任务执行器（Task Executor），一个负责提供外部接口和平台基本功能，另一个则负责文件的解析和切片处理。

触发文件解析


文件上传后，在文件列表中会有一个“解析”按钮，点击后会触发文件解析：



解析过程中，可以配置解析方法：



切片方法




梳理出 ragflow 项目中 deepdoc 模块的技术实现方案:

1、解析的文件是 pdf 时, paper_id 是 paper、是 table、是 one 或 knowledge_graph 时, 分别采用的分块策略和解析任务是如何触发并放入 Redis Stream 消息队列中, 等待任务执行器消费和处理的。

2、do_handle_task 是 RAGFlow 系统中的任务处理函数, 负责处理文档解析、分块、向量化和索引的完整流程。它的主要逻辑有哪些, 用到了哪些技术方案;

3、深入分析 DeepDoc 深度解析模块, 分析清楚 DeepDoc 内置了哪些文件的解析器, 能够解析什么类型的文件, 重点梳理出来 pdf 文件的解析技术。代码位置如下: “



任务二：构建知识库，上传

original_problems/documents/CN100342976C.pdf 文件，测试如下

问题的答案：

- 1) {"question": "根据文本信息，该静电除尘器的发明人是：", "document": "CN100342976C.pdf", "answer": "A. P · 吉特勒"}
- 2) {"question": "根据文本信息，以下哪个描述符合该静电除尘器的特征？", "document": "CN100342976C.pdf", "answer": "管状

	入口具有单个圆锥形部分，达到外壳直径的 80 至 95%，剩余部分采用台阶形式。"}} 3) {"question": "在文件中第 7 页的图片中，部件 4 相对于部件 5 在图片中的位置关系是？", "document": "CN100342976C.pdf", "answer": "部件 4 位于部件 5 的左侧"}} 4) {"question": "在文件中第 7 页的图片中，尺寸 X1, X2, X3 分别代表什么部件的间隔距离？", "document": "CN100342976C.pdf", "answer": "配气带孔盘 6, 6', 6\\之间的间隔距离"}} 5) {"question": "根据文件中第 7 页图示，气流方向(7)首先经过哪个部件？紧接着会经过哪个部件？", "document": "CN100342976C.pdf", "answer": "先经过部件 6\\", 再经过部件 6'"} 6) {"question": "根据文件中第 7 页图示，如果已知外壳直径 D, 那么 h1 和 h2 的尺寸可以用来计算什么？", "answer": "确定配气带孔盘 6, 6', 6\\的位置"}} 针对以上 6 个问题，测试在 ragflow 中的运行结果，比如第一个问题，ragflow 返回的答案不准确，需要排错：
--	--

	知识检索测试 请完成召回测试：确保你的配置可以从数据库召回正确的文本块。如果你调整了这里的默认设置，比如关键词相似度权重，请注意这里的改动不会被自动保存。请务必在聊天助手设置或者召回算子设置处同步更新相关设置。 测试设置 Rerank模型 请选择 使用知识图谱 ☐ 跨语言搜索 请选择 根据文本信息，该静电除尘器的发明人是： 运行 测试结果 测试结果未返回正确答案。 47.39 混合相似度 43.68 关键词相似度 59.82 向量相似度 10.根据权利要求7所述的静电除尘器（8），其特征在于在管状出口（9）的圆锥形部分中设有三个配气带孔盘，它们沿气流方向的透气性从41-45%增加至44-48%，然后至47-51%。静电除尘器技术领域 本发明涉及一种用于水平直流气体的静电除尘器，该除尘器具有关于中心轴线旋转对称的外壳。背景技术 这种静电过滤器从现有技术中已知，通常具有平行于外壳主轴线并等间距排列的垂直方向的片状沉积电极。这样，这些沉积电极平行于外壳主轴线等间距排列，外壳主轴线基本上在相应于圆周的各弦长可达到的全部高度上延伸。在沉积电极之间有夹紧在框架中的放电电极。此外，为了去除外壳内壁的沉淀尘埃，可设置刮擦机构，例如，可绕外壳轴线在壳壁较低的、有尘埃排出口的部位旋转的刮擦机构。这种型号的除尘器从EP0252371A1已知。这种除尘器有管状的入口和出口，它们分别由3种不同圆锥形部分所构成，圆锥形部分的大小和高度比例与除尘器的外壳直径相匹配。在中心的圆锥形部分上布置了三个配气带孔盘。这种设计类型的除尘器用于干式去除有用或无用的工业气体中的粉尘，特别是涉及到永久性或周期性的爆炸性气体混合物。例如，从正压力为1.5至2.5巴下工作的锅炉中去除高炉煤气的粉尘，以便能够在对涡轮内的能量恢复没有腐蚀性作用危险的情况下允许压力降到40至80毫巴，其中粉尘含量必须预先降到5至20毫克每立方米。考虑到有用的压力降应尽可能高，为此只考虑具有1至2毫巴压力损失的静电过滤器，因为具有同等分离性能的高性能涡气器有200至400毫巴的压力损失。这种型号除尘器的另一个应用领域是煤粉研磨工厂，那里的废气由于干燥粉尘会量而 通过调整解析方法、分块策略、向量相似度权重、ReRank 模型等各种技术实现策略（调整配置、代码实现等多种方法），实现 6 个问题的测试精度达到 100%。
工时预估	2 人日
产出物	一、任务一对应的技术总结文档 二、任务二对应的多轮测试结果、原因分析及优化方案及效果；调整后的实现代码。 三、演示 1、提供一个完整的演示视频，展示系统的功能和操作流程。 2、针对如下问题进行检索，显示检索到的答案及检索精确度： 1) {"question": "根据文本信息，该静电除尘器的发明人是：", "document": "CN100342976C.pdf", "answer": "A. P · 吉特勒"} 2) {"question": "根据文本信息，以下哪个描述符合该静电除尘器的特征？", "document": "CN100342976C.pdf", "answer": "管状

	入口具有单个圆锥形部分，达到外壳直径的 80 至 95%，剩余部分采用台阶形式。"}} 3) {"question": "在文件中第 7 页的图片中，部件 4 相对于部件 5 在图片中的位置关系是？", "document": "CN100342976C.pdf", "answer": "部件 4 位于部件 5 的左侧"}} 4) {"question": "在文件中第 7 页的图片中，尺寸 X1, X2, X3 分别代表什么部件的间隔距离？", "document": "CN100342976C.pdf", "answer": "配气带孔盘 6, 6', 6\之间的间隔距离"}} 5) {"question": "根据文件中第 7 页图示，气流方向(7)首先经过哪个部件？紧接着会经过哪个部件？", "document": "CN100342976C.pdf", "answer": "先经过部件 6\, 再经过部件 6'"}} 6) {"question": "根据文件中第 7 页图示，如果已知外壳直径 D, 那么 h1 和 h2 的尺寸可以用来计算什么？", "answer": "确定配气带孔盘 6, 6', 6\的位置"}}
验收标准	一、文档验收：文档中体现了如下三个问题清晰准确的技术实现方案总结： 解析的文件是 pdf 时，paper_id 是 paper、是 table、是 one 或 knowledge_graph 时，分别采用的分块策略和解析任务是如何触发并放入 Redis Stream 消息队列中，等待任务执行器消费和处

	理的。 do_handle_task 是 RAGFlow 系统中的任务处理函数，负责处理文档解析、分块、向量化和索引的完整流程。它的主要逻辑有哪些，用到了哪些技术方案； 深入分析 DeepDoc 深度解析模块，分析清楚 DeepDoc 内置了哪些文件的解析器，能够解析什么类型的文件，重点梳理出来 pdf 文件的解析技术。 二、功能验收：问答准确性：对于测试问题，系统能够返回准确的答案，准确率应达到 100%。 三、性能验收 1、响应时间：从用户提问到返回答案的时间应不超过 3 秒。 2、资源消耗：系统应合理利用计算资源，确保在高并发环境下稳定运行。
备注	建议使用 cursor、trae 等 AI 编程工具辅助实现。